

МИНОБРНАУКИ РОССИИ

Федеральное государственное автономное образовательное
учреждение высшего образования «Южный федеральный университет»
(ЮЖНЫЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ)

РАБОЧАЯ ПРОГРАММА ДИСЦИПЛИНЫ

Инфраструктура распределённых баз данных

Подписано электронной подписью:

Г.Е. Веселов, Директор института компьютерных
технологий и информационной безопасности

Сертификат №0643656F00F3B21B9D460D25A94BE5A817
действителен с 5 июня 2025 г. по 5 июня 2026 г.

Составитель(и) рабочей программы:

С.А. Кучеров, кандидат технических наук, доцент кафедры системного анализа и телекоммуникаций

Программа одобрена на заседании УМС Института компьютерных технологий и информационной безопасности

«19» июня 2025 г., протокол № 4

СОДЕРЖАНИЕ

I. Цели и задачи освоения дисциплины	4
II. Место дисциплины в структуре образовательной программы	4
III. Требования к результатам освоения дисциплины	5
IV. Содержание и структура дисциплины	8
4.1. Содержание дисциплины, структурированное по темам (учебным встречам) для _7_ семестра очной формы обучения	8
4.2. План внеаудиторной самостоятельной работы	24
4.3. Занятия, реализуемые в форме практической подготовки	37
V. Учебно-методическое обеспечение дисциплины	41
5.1. Основная литература	41
5.2. Дополнительная литература	41
VI. Материально-техническое обеспечение дисциплины	41
VII. Методические указания для обучающихся по освоению дисциплины	42
VIII. Фонд оценочных средств	43
8.1. Паспорт фонда оценочных средств	43
8.2. Лабораторная работа № 1. Развёртывание мини-кластера: Hadoop + Kafka + PostgreSQL (Docker)	43
8.3. Лабораторная работа №2. Интеграция PostgreSQL ↔ HDFS: экспорт, импорт, контроль форматов	44
8.4. Лабораторная работа №3. Оптимизация и профилирование SQL-запросов в PostgreSQL под аналитическую нагрузку	44
8.5. Лабораторная работа №4. Разработка Spark-job для агрегации данных из HDFS	45
8.6. Лабораторная работа №5. Построение feature-store и выгрузка признаков для модели	46
8.7. Лабораторная работа №6. Построение поиска по неструктурированным документам (JSON/documents)	46
8.8. Лабораторная работа №7. Реализация CI/CD-пайплайна для простого ETL-проекта (локальный вариант)	47
8.9. Лабораторная работа №8. Настройка мониторинга и алертов для стримингового решения	48
8.10. Лабораторная работа №9. Итоговая лаборатория: сборка и демонстрация end-to-end пайплайна (финальная интеграция для проекта)	48
8.11. Кейс-задание №1 (выполнение, подготовка отчёта, защита отчёта)	49
8.12. Кейс-задание №2 (выполнение, подготовка отчёта, защита отчёта)	51
8.13. Кейс-задание №3 (выполнение, подготовка отчёта, защита отчёта)	52
8.14. Экзаменационные вопросы и билеты для семестра 7	54

I. ЦЕЛИ И ЗАДАЧИ ОСВОЕНИЯ ДИСЦИПЛИНЫ

Цели освоения дисциплины:

– формирование у обучающихся системного понимания принципов построения, эксплуатации и масштабирования инфраструктуры распределённых баз данных, а также навыков применения технологий Big Data, DataOps и AI-oriented систем хранения и обработки данных

Задачи освоения дисциплины:

– освоение принципов проектирования архитектур распределённых БД;
– изучение инструментов оркестрации и автоматизации CI/CD и DataOps;
– освоение технологий хранения структурированных и неструктурированных данных;
– приобретение практических навыков построения и эксплуатации отказоустойчивых хранилищ больших данных.

II. МЕСТО ДИСЦИПЛИНЫ В СТРУКТУРЕ ОБРАЗОВАТЕЛЬНОЙ ПРОГРАММЫ

Дисциплина относится к части, формируемой участниками образовательных отношений, образовательной программы и входит в модуль вариативных профессиональных компетенций.

Для изучения данной дисциплины необходимы знания, умения и навыки, формируемые предшествующими элементами образовательной программы:

Наименование дисциплины (модуля), практики	Требуемые знания, умения, навыки
Алгоритмизация и программирование	Знания: – особенности программирования в современных инструментальных средах – типы и структуры данных – принципы построения программ на языках высокого уровня – синтаксис и семантика языков программирования высокого уровня
	Умения: – алгоритмизация действий по решению задачи – оптимизация алгоритмов
	Навыки: – написание программ на языках высокого уровня
Базы данных и СУБД	Знания: – современные технологии хранения неструктурированных данных – NoSQL системы управления базами данных
	Умения: – организация хранения неструктурированных данных – написание процедур CRUD для неструктурированных данных – разработка объектов баз данных
	Навыки: – работа с NoSQL СУБД и встроенными языками

Знания, умения и навыки, формируемые данной дисциплиной, потребуются при освоении следующих элементов образовательной программы:

- преддипломная практика;
- подготовка к защите и защита выпускной квалификационной работы

III. ТРЕБОВАНИЯ К РЕЗУЛЬТАТАМ ОСВОЕНИЯ ДИСЦИПЛИНЫ

Освоение дисциплины направлено на формирование следующих компетенций в соответствии с образовательным стандартом и образовательной программой:

Перечень планируемых результатов обучения по дисциплине, соотнесённых с индикаторами достижения компетенций

Компетенция	Индикаторы достижения компетенции	Результаты обучения
ПК-6. BD-3 Способен организовывать хранение данных, выбирая адекватные технологические решения	ПК-6.1 BD-3.1 Разрабатывает, отлаживает и тестирует прикладные решения с элементами ИИ с применением различных технологий хранения структурированных данных, оценивает качество	Знания: – свойства реляционных и колонковых СУБД (PostgreSQL, ClickHouse/аналоги), модели хранения структурированных данных, индексирование, транзакционность, CAP/ACID/BASE в контексте ИИ-приложений; – метрики качества данных и моделей для структурированных данных (accuracy, precision/recall, AUC, data drift)
		Умения: – выбирать и настраивать технологии хранения (PostgreSQL, OLAP-решения) для задач подготовки признаков и онлайн-поддачи в модели; – реализовывать ETL для структурированных наборов, проводить профилирование и очистку данных; – интегрировать хранение с модельными сервисами.
		Навыки: – оптимизации запросов, схем данных, создание feature stores на базе реляционных/колонковых хранилищ и тестирование надёжности/скорости доступа для ML-пайплайнов.
	ПК-6.2 BD-3.2 Разрабатывает, отлаживает и тестирует прикладные решения с элементами ИИ с применением различных технологий хранения неструктурированных данных, оценивает качество	Знания: – форматы и требования к хранению неструктурированных данных (файловые хранилища, object storage, JSON/Avro/Parquet, документо-ориентированные БД), методы индексирования текста/изображений/видео, метрики качества для мультимодальных данных Умения: – проектировать решения для хранения и доступа к неструктурированным данным (например: MinIO/S3-совместимое хранилище, HDFS, MongoDB), реализовывать предобработку (парсинг, нормализация, векторизация), интегрировать с AI-моделями (batch/online inference)

Компетенция	Индикаторы достижения компетенции	Результаты обучения
		Навыки: – владение практикой построения и поддержки хранилищ больших бинарных и текстовых данных; применением инструментов для индексирования/поиска; – обеспечение консистентности и доступности медиаданных в распределённых окружениях
ПК-15. BD-2 Способен определять требования к наборам данных для решения задач машинного обучения, проводить разметку и анализ наборов данных, оценивать качество данных, обеспечивать непрерывную интеграцию данных	ПК-15.2 BD-2.3 Применяет инструменты и практики непрерывной интеграции данных (DataOps)	Знания: – принципы DataOps, CI/CD для данных, жизненный цикл данных, архитектурные паттерны для автоматизации пайплайнов, ключевые метрики качества и надежности конвейеров данных; – инструменты оркестрации и мониторинга (общая семантика — Airflow, Jenkins, Git, Docker, Prometheus/ELK — без привязки к провайдеру).
		Умения: – проектировать и реализовывать автоматизированные конвейеры обработки и валидации данных; – настраивать версионирование артефактов данных и кода; – внедрять тесты качества данных (unit, regression, schema tests) и механизмы оповещений/ревертов
		Навыки: – конфигурирования CI для ETL/ELT (скрипты, контейнеры, пайплайны), инструментами мониторинга и логирования, а также владение методиками аудита и трассировки данных в распределённых системах
ВПК-3. Способен решать задачи инженерии данных в области разработки ИИ-решений для цифровизации бизнес-процессов	ВПК-3.6. BD-4.1 Осуществляет выбор технологий обработки больших данных, приемлемых для создания прикладной системы ИИ с заданными требованиями	Знания: – парадигмы распределённой обработки (map-reduce, stream processing), возможности и ограничения Hadoop-экосистемы, Spark и Kafka; критерии оценки (латентность, пропускная способность, устойчивость, стоимость, консистентность)
		Умения: – оценивать требования прикладной ИИ-системы (throughput, latency, SLA) и сопоставлять их с характеристиками технологий; строить аргументированные обоснования выбора архитектурных компонентов и конфигураций
		Навыки: – методикой сравнения и приёмы прототипирования производительности (benchmarks), настройкой кластеров обработки и интеграцией выбранных технологий в общий стек

Компетенция	Индикаторы достижения компетенции	Результаты обучения
	ВПК-3.7. BD-4.2 Разрабатывает и отлаживает прикладные решения с элементами ИИ с применением различных технологий обработки данных	Знания: – принципы разработки распределённых вычислительных задач для обучения/вычисления признаков, шаблоны «batch vs stream», способы управления состоянием и обеспечения идемпотентности
		Умения: – реализовывать ETL/ELT и feature-engineering на распределённых платформах (Hadoop/Spark), отлаживать производительность, обеспечивать повторяемость экспериментов и воспроизводимость
		Навыки: – практическими навыками разработки и профилирования Spark-задач, управления ресурсами (YARN/Kubernetes), а также интеграции обработки с хранилищами данных и системами развертывания моделей
	ВПК-3.8. BD-5.1 Осуществляет выбор направления вспомогательных технологических решений для формирования единого стека работы с большими данными для решения поставленной задачи	Знания: – составные части «единого стека» (data ingestion, storage, processing, serving, orchestration, monitoring, security), роль вспомогательных инструментов (контейнеризация, конфигурирование, IaC и т.д.), вопросы совместимости и лицензирования
		Умения: – проектировать единый стек (stack) под конкретную задачу — интегрируя Kafka/Hadoop/PostgreSQL/объектное хранилище/оркестрацию/CI; проводить оценку рисков и затрат
		Навыки: – настройки вспомогательных компонентов (Docker, Helm/K8s манифесты, базовая Terraform/Ansible), обеспечение непрерывности и воспроизводимости среды разработки и эксплуатации

IV. СОДЕРЖАНИЕ И СТРУКТУРА ДИСЦИПЛИНЫ

Трудоёмкость дисциплины составляет 8 зачётных единиц, 288 часов,
в том числе 1 зачётная единица, 36 часов на экзамен (при наличии)

Форма промежуточной аттестации: экзамен

4.1. Содержание дисциплины, структурированное по темам (учебным встречам) для _7_ семестра очной формы обучения

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
Модуль 1. Фундамент: принципы распределённых данных и инструменты										
1	Тема 1. Введение в распределённые базы данных и большие данные Рассматриваемые вопросы: Понятие распределённых данных и принципы масштабирования. Модели согласованности: CAP-теорема, ACID vs BASE. Архитектуры распределённых СУБД. Сравнение традиционных и распределённых СУБД. Роль Data Engineer в современной инфраструктуре данных.	2	—	—	—	2	Информационная лекция	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
2	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Концепция Hadoop и архитектура HDFS. Компоненты: NameNode, DataNode, Secondary NameNode. Надёжность, репликация, отказоустойчивость. MapReduce — принципы, пример реализации. Использование HDFS для хранения больших данных.	2	—	—	—	2	Информационная лекция	—	—	—
3	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Работа с HDFS: загрузка, чтение, репликация файлов.	—	2	—	—	2	Семинар	—	—	—
4	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Написание простых MapReduce-задач (WordCount, сортировка).	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
5	Тема 3. Apache Kafka — платформа потоковой передачи данных Рассматриваемые вопросы: Архитектура Kafka: брокеры, продюсеры, консюмеры. Темы, партиции, офсеты. Модели доставки: at-most-once, at-least-once, exactly-once. Интеграция Kafka с Hadoop и PostgreSQL. Применение Kafka в потоковых пайплайнах.	2	—	—	—	2	Информационная лекция	—	—	—
6	Тема 3. Apache Kafka — платформа потоковой передачи данных Рассматриваемые вопросы: Развёртывание Kafka, создание тем и консумеров.	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
7	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Архитектура PostgreSQL, организация хранения и транзакций. Индексы, оптимизация запросов, типы данных. Репликация и шардирование PostgreSQL. Расширяемость (FDW, PostGIS, PL/Python). Роль PostgreSQL в гибридных архитектурах данных.	2	—	—	—	2	Информационная лекция	—	—	—
8	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Конфигурация PostgreSQL, создание базы и таблиц.	—	2	—	—	2	Семинар	—	—	—
9	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Выполнение и оптимизация SQL-запросов.	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
10	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Развёртывание мини-кластера Hadoop + Kafka + PostgreSQL (Docker).	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 1	<i>подготовка и сдача отчета по лабораторной работе</i>	5
11	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: CSV, JSON, Avro, ORC, Parquet: сравнение, компрессия, типизация. Оптимальный выбор формата под задачу (batch vs stream). Эволюция схемы (schema registry). Практика совместимости форматов при переносе данных.	2	–	–	–	2	Информационная лекция	–	–	–
12	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Интеграция PostgreSQL ↔ HDFS: экспорт, импорт, контроль форматов.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 2	<i>подготовка и сдача отчета по лабораторной работе</i>	5
13	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Конвертация данных между CSV, JSON и Parquet.	–	2	–	–	2	Семинар	–	–	–

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
14	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Реализация простого потока Kafka → PostgreSQL.	–	2	–	–	2		–	–	–
15	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Оптимизация и профилирование SQL-запросов под аналитическую нагрузку.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 3	<i>подготовка и сдача отчета по лабораторной работе</i>	5
16	Тема 6. Безопасность и управление доступом в распределённых хранилищах Рассматриваемые вопросы: Аутентификация и авторизация в Hadoop, Kafka, PostgreSQL. Роли и политики доступа, Kerberos и TLS. Шифрование данных на уровне хранения и передачи. Резервное копирование, аудит и восстановление.	2	–	–	–	2	Информационная лекция	–	–	–
17	Тема 6. Безопасность и управление доступом в распределённых хранилищах Рассматриваемые вопросы: Резервное копирование и восстановление данных в PostgreSQL.	–	2	–	–	2	Семинар	–	–	–

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
18	Тема 6. Безопасность и управление доступом в распределённых хранилищах Рассматриваемые вопросы: Проверка качества и целостности данных.	—	2	—	—	2	Семинар	Кейс-задание № 1 (выполнение, подготовка отчёта, защита отчёта)	Защита отчёта	5
Модуль 2. Хранилища и обработка: от данных к признакам										
19	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Архитектура Spark: драйвер, ехесutor, кластерный менеджер. Принципы RDD и DataFrame API. Spark SQL, кеширование и оптимизация. Работа со структурированными и неструктурированными данными.	2	—	—	—	2	Информационная лекция	—	—	—
20	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Создание Spark-проекта, работа с DataFrame.	—	2	—	—	2	Семинар	—	—	—
21	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Обработка данных из HDFS.	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
22	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Отличия пакетной и потоковой обработки. Примеры решений: Spark Streaming, Kafka Streams. Семантика событий и окна (windowing). Гарантии доставки и порядок обработки сообщений.	2	—	—	—	2	Информационная лекция	—	—	—
23	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Реализация потокового конвейера Kafka → Spark.	—	2	—	—	2	Семинар	—	—	—
24	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Создание денормализованных схем данных.	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
25	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Сравнение моделей: нормализация и денормализация. Star и Snowflake схемы. Индексирование, партиционирование, материализованные представления. Data Lake и Data Warehouse: интеграция и различия.	2	–	–	–	2	Информационная лекция	–	–	–
26	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Хранение неструктурированных данных (JSON/файлы).	–	2	–	–	2	Семинар	–	–	–
27	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка feature pipeline для ML-задачи.	–	2	–	–	2	Семинар	–	–	–
28	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка Spark-приложения для агрегации данных из HDFS.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 4	подготовка и сдача отчета по лабораторной работе	5

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
29	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Объектные хранилища (S3, MinIO, HDFS). Документо-ориентированные БД (MongoDB, Elasticsearch). Метаданные и каталоги данных. Применение для текстов, изображений, аудио и видео.	2	–	–	–	2	Информационная лекция	–	–	–
30	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Оценка производительности обработки.	–	2	–	–	2	Семинар	–	–	–
31	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Применение простых ML-моделей на обработанных данных.	–	2	–	–	2	Семинар	–	–	–

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)					Формат проведения занятия	Наименование оценочного средств ва	Вид контроля	Сумма баллов за занятие
		Контактная работа				Самостоя- тельная работа				
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
32	Тема 11. Feature Engineering и Feature Stores Рассматриваемые вопросы: Концепция feature store. Версионирование признаков, контроль качества и lineage. Реализация feature pipeline. Хранение признаков в PostgreSQL, HDFS, Parquet.	2	–	–	–	2	Информационная лекция	–	–	–
33	Тема 11. Feature Engineering и Feature Stores Рассматриваемые вопросы: Построение feature store и выгрузка признаков для модели.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 5	подготовка и сдача отчета по лабораторной работе	5
34	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Компрессия, сериализация, партиционирование. Lazy evaluation, broadcast joins, shuffle. Распределение нагрузки и профилирование. Интеграция Spark ↔ PostgreSQL ↔ Kafka.	2	–	–	–	2	Информационная лекция	–	–	–
35	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Интеграция результатов в PostgreSQL.	–	2	–	–	2	Семинар	Кейс-задание № 2 (выполнение, подготовка отчёта, защита отчёта)	Защита отчёта	5

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
36	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Анализ производительности и оптимизация Spark-задания.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 6	<i>подготовка и сдача отчета по лабораторной работе</i>	5
Модуль 3. DataOps, эксплуатация и проект										
37	Тема 13. Принципы DataOps Рассматриваемые вопросы: Концепция DataOps и DevOps для данных. CI/CD-практики в конвейерах данных. Версионирование схем и данных. Роль тестов качества и мониторинга.	2	–	–	–	2	Информационная лекция	–	–	–
38	Тема 13. Принципы DataOps Рассматриваемые вопросы: Создание CI/CD пайплайна для ETL.	–	2	–	–	2	Семинар	–	–	–
39	Тема 13. Принципы DataOps Рассматриваемые вопросы: Автоматическое тестирование схем данных.	–	2	–	–	2	Семинар	–	–	–
40	Тема 13. Принципы DataOps Рассматриваемые вопросы: Реализация CI/CD пайплайна (Git + Docker).	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 7	<i>подготовка и сдача отчета по лабораторной работе</i>	5

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
41	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: DAG, зависимости и SLA. Примеры инструментов (Airflow, Prefect). Планирование задач, retry и алерты. Мониторинг выполнения пайплайнов.	2	—	—	—	2	Информационная лекция	—	—	—
42	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Внедрение unit-тестов для Spark-задач.	—	2	—	—	2	Семинар	—	—	—
43	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Настройка мониторинга Kafka.	—	2	—	—	2	Семинар	—	—	—
44	Тема 15. Мониторинг и трассировка данных Рассматриваемые вопросы: Метрики данных и приложений. Data quality dashboard. Логирование и трассировка (ELK, Prometheus, Grafana). SLA и SLO для данных.	2	—	—	—	2	Информационная лекция	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средств а	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
45	Тема 15. Мониторинг и трассировка данных Рассматриваемые вопросы: Настройка мониторинга и алертов.	—	—	4	—	4	Репродуктивная лабораторная работа	лабораторная работа № 8	<i>подготовка и сдача отчета по лабораторной работе</i>	5
46	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Основы Docker, Dockerfile. Управление конфигурациями, Compose. Введение в Kubernetes. Infrastructure as Code (Terraform, Ansible).	2	—	—	—	2	Информационная лекция	—	—	—
47	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Контейнеризация ETL-микросервиса.	—	2	—	—	2	Семинар	—	—	—
48	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Визуализация метрик (Grafana).	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
49	Тема 17. Безопасность и эксплуатация Рассматриваемые вопросы: Политики доступа и управление секретами. Управление версиями и инцидентами. Обеспечение отказоустойчивости. Практика восстановления пайплайнов.	2	—	—	—	2	Информационная лекция	—	—	—
50	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Методика проектной работы. Описание требований и критериев оценки. Формат отчётности и защита.	2	—	—	—	2	Информационная лекция	—	—	—
51	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Обработка инцидентов и rollback.	—	2	—	—	2	Семинар	—	—	—
52	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Code review проектных решений.	—	2	—	—	2	Семинар	—	—	—

№ п/п	Тема занятия и рассматриваемые вопросы	Виды учебной работы и их трудоёмкость, часы (в том числе с использованием онлайн-курсов)				Самостоя- тельная работа	Формат проведения занятия	Наименование оценочного средст ва	Вид контроля	Сумма баллов за занятие
		Контактная работа								
		Лекции	Практичес кие	Лаборатор ные	Консультац ии					
53	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: сборка и демонстрация end-to-end пайплайна.	–	–	4	–	4	Репродуктивная лабораторная работа	лабораторная работа № 9	<i>подготовка и сдача отчета по лабораторной работе</i>	5
54	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Подготовка и защита мини-проекта.	–	2	–	–	2	Семинар	Кейс-задание № 3 (выполнение, подготовка отчёта, защита отчёта)	Защита отчёта	5
Промежуточная аттестация		–	–	–	–	36		Экзамнационные вопросы и билеты для семестра 7	<i>экзамен</i>	40
Итого часов		36	54	36		162		–		100

4.2. План внеаудиторной самостоятельной работы

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно-методическое обеспечение
Модуль 1. Фундамент: принципы распределённых данных и инструменты						
1	Тема 1. Введение в распределённые базы данных и большие данные Рассматриваемые вопросы: Понятие распределённых данных и принципы масштабирования. Модели согласованности: CAP-теорема, ACID vs BASE. Архитектуры распределённых СУБД. Сравнение традиционных и распределённых СУБД. Роль Data Engineer в современной инфраструктуре данных.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к контрольной работе	2	[1] – [10]
2	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Концепция Hadoop и архитектура HDFS. Компоненты: NameNode, DataNode, Secondary NameNode. Надёжность, репликация, отказоустойчивость. MapReduce — принципы, пример реализации. Использование HDFS для хранения больших данных.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
3	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Работа с HDFS: загрузка, чтение, репликация файлов.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
4	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Написание простых MapReduce-задач (WordCount, сортировка).	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
5	Тема 3. Apache Kafka — платформа потоковой передачи данных Рассматриваемые вопросы: Архитектура Kafka: брокеры, продюсеры, консюмеры. Темы, партиции, офсеты. Модели доставки: at-most-once, at-least-once, exactly-once. Интеграция Kafka с Hadoop и PostgreSQL. Применение Kafka в потоковых пайплайнах.	7	1-6	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
6	Тема 3. Apache Kafka — платформа потоковой передачи данных Рассматриваемые вопросы: Развёртывание Kafka, создание тем и консумеров.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
7	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Архитектура PostgreSQL, организация хранения и транзакций. Индексы, оптимизация запросов, типы данных. Репликация и шардирование PostgreSQL. Расширяемость (FDW, PostGIS, PL/Python). Роль PostgreSQL в гибридных архитектурах данных.	7	1-6	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
8	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Конфигурация PostgreSQL, создание базы и таблиц.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
9	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Выполнение и оптимизация SQL-запросов.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
10	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Развёртывание мини-кластера Hadoop + Kafka + PostgreSQL (Docker).	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
11	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: CSV, JSON, Avro, ORC, Parquet: сравнение, компрессия, типизация. Оптимальный выбор формата под задачу (batch vs stream). Эволюция схемы (schema registry). Практика совместимости форматов при переносе данных.	7	1-6	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
12	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Интеграция PostgreSQL ↔ HDFS: экспорт, импорт, контроль форматов.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
13	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Конвертация данных между CSV, JSON и Parquet.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
14	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Реализация простого потока Kafka → PostgreSQL.	7	1-6	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
19	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Архитектура Spark: драйвер, executor, кластерный менеджер. Принципы RDD и DataFrame API. Spark SQL, кеширование и оптимизация. Работа со структурированными и неструктурированными данными.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
20	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Создание Spark-проекта, работа с DataFrame.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
21	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Обработка данных из HDFS.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
22	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Отличия пакетной и потоковой обработки. Примеры решений: Spark Streaming, Kafka Streams. Семантика событий и окна (windowing). Гарантии доставки и порядок обработки сообщений.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
23	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Реализация потокового конвейера Kafka → Spark.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
24	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Создание денормализованных схем данных.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
25	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Сравнение моделей: нормализация и денормализация. Star и Snowflake схемы. Индексирование, партиционирование, материализованные представления. Data Lake и Data Warehouse: интеграция и различия.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
26	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Хранение неструктурированных данных (JSON/файлы).	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
27	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка feature pipeline для ML-задачи.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
28	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка Spark-приложения для агрегации данных из HDFS.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
29	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Объектные хранилища (S3, MinIO, HDFS). Документно-ориентированные БД (MongoDB, Elasticsearch). Метаданные и каталоги данных. Применение для текстов, изображений, аудио и видео.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
30	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Оценка производительности обработки.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
31	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Применение простых ML-моделей на обработанных данных.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
32	Тема 11. Feature Engineering и Feature Stores Рассматриваемые вопросы: Концепция feature store. Версионирование признаков, контроль качества и lineage. Реализация feature pipeline. Хранение признаков в PostgreSQL, HDFS, Parquet.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
33	Тема 11. Feature Engineering и Feature Stores Рассматриваемые вопросы: Построение feature store и выгрузка признаков для модели.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
34	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Компрессия, сериализация, партиционирование. Lazy evaluation, broadcast joins, shuffle. Распределение нагрузки и профилирование. Интеграция Spark ↔ PostgreSQL ↔ Kafka.	7	7-12	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
35	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Интеграция результатов в PostgreSQL.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
36	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Анализ производительности и оптимизация Spark-задания.	7	7-12	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
Модуль 3. DataOps, эксплуатация и проект						
37	Тема 13. Принципы DataOps Рассматриваемые вопросы: Концепция DataOps и DevOps для данных. CI/CD-практики в конвейерах данных. Версионирование схем и данных. Роль тестов качества и мониторинга.	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
38	Тема 13. Принципы DataOps Рассматриваемые вопросы: Создание CI/CD пайплайна для ETL.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
39	Тема 13. Принципы DataOps Рассматриваемые вопросы: Автоматическое тестирование схем данных.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
40	Тема 13. Принципы DataOps Рассматриваемые вопросы: Реализация CI/CD пайплайна (Git + Docker).	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
41	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: DAG, зависимости и SLA. Примеры инструментов (Airflow, Prefect). Планирование задач, retry и алерты. Мониторинг выполнения пайплайнов.	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
42	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Внедрение unit-тестов для Spark-задач.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
43	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Настройка мониторинга Kafka.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
44	Тема 15. Мониторинг и трассировка данных Рассматриваемые вопросы: Метрики данных и приложений. Data quality dashboard. Логирование и трассировка (ELK, Prometheus, Grafana). SLA и SLO для данных.	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
45	Тема 15. Мониторинг и трассировка данных Рассматриваемые вопросы: Настройка мониторинга и алертов.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
46	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Основы Docker, Dockerfile. Управление конфигурациями, Compose. Введение в Kubernetes. Infrastructure as Code (Terraform, Ansible).	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
47	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Контейнеризация ETL-микросервиса.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
48	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Визуализация метрик (Grafana).	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
49	Тема 17. Безопасность и эксплуатация Рассматриваемые вопросы: Политики доступа и управление секретами. Управление версиями и инцидентами. Обеспечение отказоустойчивости. Практика восстановления пайплайнов.	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]

№ п/п	Тема занятия	Семестр	Сроки выполнения (нед.)	Вид самостоятельной работы	Затраты времени (часы)	Учебно- методическое обеспечение
50	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Методика проектной работы. Описание требований и критериев оценки. Формат отчётности и защита.	7	13-18	– проработка и повторение материала лекционных занятий; подготовка к контрольной работе	2	[1] – [10]
51	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Обработка инцидентов и rollback.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
52	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Code review проектных решений.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
53	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: сборка и демонстрация end-to-end пайплайна.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к лабораторным работам, подготовка отчётов о выполнении лабораторных работ, подготовка к защите отчётов о выполнении лабораторных работ	4	[1] – [10]
54	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Подготовка и защита мини-проекта.	7	13-18	– проработка и повторение материала лекционных занятий; – подготовка к практическим работам, подготовка отчётов о выполнении практических работ, подготовка к защите отчётов о выполнении практических работ	2	[1] – [10]
Подготовка к экзамену					36	[1]–[8]
Общая трудоёмкость самостоятельной работы по дисциплине					162	–

4.3. Занятия, реализуемые в форме практической подготовки

№ п/п	Тема занятия	Вид учебной работы	Формат проведения занятия	Место проведения занятия	Объем в часах
1	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Работа с HDFS: загрузка, чтение, репликация файлов.	Практическое занятие	Семинар	ЮФУ	2
2	Тема 2. Экосистема Hadoop и HDFS Рассматриваемые вопросы: Написание простых MapReduce-задач (WordCount, сортировка).	Практическое занятие	Семинар	ЮФУ	2
3	Тема 3. Apache Kafka — платформа потоковой передачи данных Рассматриваемые вопросы: Развёртывание Kafka, создание тем и консумеров.	Практическое занятие	Семинар	ЮФУ	2
4	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Конфигурация PostgreSQL, создание базы и таблиц.	Практическое занятие	Семинар	ЮФУ	2
5	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Выполнение и оптимизация SQL-запросов.	Практическое занятие	Семинар	ЮФУ	2
6	Тема 4. PostgreSQL: реляционное ядро инфраструктуры Рассматриваемые вопросы: Развёртывание мини-кластера Hadoop + Kafka + PostgreSQL (Docker).	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
7	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Интеграция PostgreSQL ↔ HDFS: экспорт, импорт, контроль форматов.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
8	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Конвертация данных между CSV, JSON и Parquet.	Практическое занятие	Семинар	ЮФУ	2
9	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Реализация простого потока Kafka → PostgreSQL.	Практическое занятие	Семинар	ЮФУ	2

10	Тема 5. Форматы данных и сериализация Рассматриваемые вопросы: Оптимизация и профилирование SQL-запросов под аналитическую нагрузку.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
11	Тема 6. Безопасность и управление доступом в распределённых хранилищах Рассматриваемые вопросы: Резервное копирование и восстановление данных в PostgreSQL.	Практическое занятие	Семинар	ЮФУ	2
12	Тема 6. Безопасность и управление доступом в распределённых хранилищах Рассматриваемые вопросы: Проверка качества и целостности данных.	Практическое занятие	Семинар	Площадка индустриального партнёра	2
13	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Создание Spark-проекта, работа с DataFrame.	Практическое занятие	Семинар	ЮФУ	2
14	Тема 7. Распределённая обработка данных на Spark Рассматриваемые вопросы: Обработка данных из HDFS.	Практическое занятие	Семинар	ЮФУ	2
15	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Реализация потокового конвейера Kafka → Spark.	Практическое занятие	Семинар	ЮФУ	2
16	Тема 8. Batch vs Stream: парадигмы обработки Рассматриваемые вопросы: Создание денормализованных схем данных.	Практическое занятие	Семинар	ЮФУ	2
17	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Хранение неструктурированных данных (JSON/файлы).	Практическое занятие	Семинар	ЮФУ	2
18	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка feature pipeline для ML-задачи.	Практическое занятие	Семинар	ЮФУ	2
19	Тема 9. Проектирование хранилищ: OLTP и OLAP Рассматриваемые вопросы: Разработка Spark-приложения для агрегации данных из HDFS.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
20	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Оценка производительности обработки.	Практическое занятие	Семинар	ЮФУ	2

21	Тема 10. Хранение неструктурированных данных Рассматриваемые вопросы: Применение простых ML-моделей на обработанных данных.	Практическое занятие	Семинар	ЮФУ	2
22	Тема 11. Feature Engineering и Feature Stores Рассматриваемые вопросы: Построение feature store и выгрузка признаков для модели.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
23	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Интеграция результатов в PostgreSQL.	Практическое занятие	Семинар	Площадка индустриального партнёра	2
24	Тема 12. Оптимизация передачи данных Рассматриваемые вопросы: Анализ производительности и оптимизация Spark-задания.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
25	Тема 13. Принципы DataOps Рассматриваемые вопросы: Создание CI/CD пайплайна для ETL.	Практическое занятие	Семинар	ЮФУ	2
26	Тема 13. Принципы DataOps Рассматриваемые вопросы: Автоматическое тестирование схем данных.	Практическое занятие	Семинар	ЮФУ	2
27	Тема 13. Принципы DataOps Рассматриваемые вопросы: Реализация CI/CD пайплайна (Git + Docker).	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
28	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Внедрение unit-тестов для Spark-задач.	Практическое занятие	Семинар	ЮФУ	2
29	Тема 14. Оркестрация пайплайнов Рассматриваемые вопросы: Настройка мониторинга Kafka.	Практическое занятие	Семинар	ЮФУ	2
30	Тема 15. Мониторинг и трассировка данных Рассматриваемые вопросы: Настройка мониторинга и алертов.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
31	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы: Контейнеризация ETL-микросервиса.	Практическое занятие	Семинар	ЮФУ	2
32	Тема 16. Контейнеризация и развертывание Рассматриваемые вопросы:	Практическое занятие	Семинар	ЮФУ	2

	Визуализация метрик (Grafana).				
33	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Обработка инцидентов и rollback.	Практическое занятие	Семинар	ЮФУ	2
34	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Code review проектных решений.	Практическое занятие	Семинар	ЮФУ	2
35	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: сборка и демонстрация end-to-end пайплайна.	Лабораторное занятие	Репродуктивная лабораторная работа	ЮФУ	4
36	Тема 18. Итоговый проект и оценивание Рассматриваемые вопросы: Подготовка и защита мини-проекта.	Практическое занятие	Семинар	Площадка индустриального партнёра	2
ИТОГО:					90

V. УЧЕБНО-МЕТОДИЧЕСКОЕ ОБЕСПЕЧЕНИЕ ДИСЦИПЛИНЫ

5.1. Основная литература

1. Gkamas, T., “Performance Evaluation of Distributed Database Strategies for Cloud-Centric Sensory Measurements,” Information, Vol. 13, Issue 4, 2022. DOI: 10.3390/info13040190. <https://www.mdpi.com/2078-2489/13/4/190>
2. Duan, Z., “Research on Distributed Storage Technology of Database Big Data Based on Cloud Computing,” Information Systems Engineering, 2019 (or 2020), HillPublisher. https://wap.hillpublisher.com/ArticleDetails.aspx?cid=1889&utm_source=chatgpt.com
3. Ma, C., “An overview of Hadoop applications in transportation big data,” Transportation Research Part C: Emerging Technologies, 2023. DOI (указан на сайте) — (точный DOI надо проверить) <https://www.sciencedirect.com/science/article/pii/S2095756423001009>
4. Zhou, Z., Zhou, L., Chen, Z., “A Distributed Real-Time Monitoring Scheme for Air Pressure Stream Data Based on Kafka,” Applied Sciences, Vol. 14 (12), 2024. DOI: 10.3390/app14124967. <https://www.mdpi.com/2076-3417/14/12/4967>
5. Akanbi, A., et al., “A Distributed Stream Processing Middleware Framework,” Sensors (или PMC open source), 2020. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7308861/>
6. Tsai, C. W., et al., “Big data analytics: a survey,” Journal of Big Data, SpringerOpen, 2015. DOI: 10.1186/s40537-015-0030-3. <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-015-0030-3>
7. Berloco, F., “Distributed Analytics For Big Data: A Survey,” 2024. (ScienceDirect) <https://www.sciencedirect.com/science/article/abs/pii/S0925231224000298>
8. “A Comprehensive Survey on Big Data Analytics,” ACM, 2025. DOI: 10.1145/3718364. <https://dl.acm.org/doi/10.1145/3718364>

5.2. Дополнительная литература

9. Leang, B., “Improvement of Kafka Streaming Using Partition and Multi-...”, Sensors, 2019. DOI: 10.3390/s19010134. <https://www.mdpi.com/1424-8220/19/1/134>
10. Kumar, F. Pawan, “Real-Time Data Processing and Distributed System Optimization with Kafka And Cassandra,” IRJAEM, Vol. 3, Issue 08, Aug 2025. DOI: 10.47392/IRJAEM.2025.0424. https://www.researchgate.net/publication/394637291_Real-Time_Data_Processing_and_Distributed_System_Optimization_with_Kafka_And_Cassandra

VI. МАТЕРИАЛЬНО-ТЕХНИЧЕСКОЕ ОБЕСПЕЧЕНИЕ ДИСЦИПЛИНЫ

При реализации дисциплины используются следующие помещения, оборудование и программное обеспечение:

№ п/п	Тип аудиторного занятия	Рекомендуемая аудитория	
		Тип	Оснащение
1	Лекционные занятия	Лекционная аудитория	– Мультимедийный проектор; – Экран.
3	Практические занятия	Компьютерный класс	– Интерактивная доска с проектором; – Персональные компьютеры (25 шт.); – СУБД PostgreSQL или PostgresPRO; – ОС Microsoft Windows или РЕД ОС; – PgAdmin; – Microsoft Office или Мой офис – Hadoop – Kafka – Docker

№ п/п	Тип аудиторного занятия	Рекомендуемая аудитория	
		Тип	Оснащение
4	Самостоятельная работа	Помещение для самостоятельной работы	– Интерактивная доска с проектором; – Персональные компьютеры (25 шт.); – СУБД PostgreSQL или PostgresPRO; – ОС Microsoft Windows или РЕД ОС; – PgAdmin; – Microsoft Office или Мой офис – Hadoop – Kafka – Docker

VII. МЕТОДИЧЕСКИЕ УКАЗАНИЯ ДЛЯ ОБУЧАЮЩИХСЯ ПО ОСВОЕНИЮ ДИСЦИПЛИНЫ

Учебный процесс обучения по дисциплине включает в себя аудиторные занятия (лекции, лабораторные и практические занятия) и самостоятельную работу. Итоговый контроль по дисциплине – экзамен. Лектор и преподаватели, ведущие лабораторные занятия, контролируют посещение всех видов аудиторных занятий.

Подготовка к лекциям. Знакомство с дисциплиной происходит уже на первой лекции. От студента требуется не просто внимание, но и самостоятельное оформление конспекта. При работе с конспектом лекций необходимо учитывать тот фактор, что одни лекции дают ответы на конкретные вопросы темы, другие – лишь выявляют взаимосвязи между явлениями, помогая студенту понять глубинные процессы развития изучаемого предмета, как в истории, так и в настоящее время.

Практические занятия состоят из разбора и выполнения общего задания вместе с преподавателем и работы над выполнением самостоятельного задания. Результаты выполненной работы демонстрируются преподавателю в виде подготовленных отчетов. По результатам выполнения заданий каждого из разделов студент получает баллы, сумма которых определяет итоговую оценку.

Лабораторные занятия состоят из разбора и выполнения общего задания вместе с преподавателем и работы над выполнением самостоятельного задания. Результаты выполненной работы демонстрируются преподавателю в виде подготовленных отчетов. По результатам выполнения заданий каждого из разделов студент получает баллы, сумма которых определяет итоговую оценку.

Самостоятельная работа студентов включает в себя подготовку к лекционным занятиям, лабораторным и практическим работам.

Этика использования искусственного интеллекта. При освоении данного курса допускается использование технологий искусственного интеллекта с явным указанием мест использования полученных результатов в отчетах по практическим работам. Направления, в которых допускается использование технологий искусственного интеллекта:

- информационный поиск;
- генерация наборов исходных данных;
- разработка макетов документов;
- формирование альтернатив при выборе.

Бонусные баллы начисляются за сертификаты, полученные в ходе освоения онлайн-курсов по теме цифровизации бизнес-процессов.

Обязательным условием получения допуска к экзамену по дисциплине является выполнение всех лабораторных работ и кейсовых заданий с получением минимальной положительной оценки

VIII. ФОНД ОЦЕНОЧНЫХ СРЕДСТВ

8.1. Паспорт фонда оценочных средств

№ п/п	Код индикатора достижения компетенции	Наименование оценочного средства
1	ПК-6.1	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты
2	ПК-6.2	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты
3	ПК-15.2	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты
4	ВПК-3.6.	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты
5	ВПК-3.7.	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты
6	ВПК-3.8.	– кейс-задания №№ 1-3; – лабораторные работы №№ 1-9; – экзаменационные вопросы и билеты

8.2. Лабораторная работа № 1. Развёртывание мини-кластера: Hadoop + Kafka + PostgreSQL (Docker)

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 1-6

Форма обучения: очная

Цель: научиться развертывать локальную интегрированную среду (контейнеры Docker Compose) с HDFS, Kafka и PostgreSQL, проверять взаимодействие компонентов.

План выполнения:

1. Подготовка окружения: Docker + Docker Compose.
2. Создание `docker-compose.yml` с сервисами: `zookeeper`, `kafka`, `namenode/datanode` (HDFS), `postgres`.
3. Конфигурация томов, сетей и переменных среды.
4. Запуск и проверка статуса всех сервисов.
5. Простейшая интеграция: записать файл в HDFS, отправить сообщение в Kafka, вставить запись в PostgreSQL.
6. Сбор логов и создание отчёта о настройке.

Варианты задания:

1. Сконфигурировать HDFS с репликацией 2.
2. Использовать образ Kafka с JMX enabled и задать нестандартный порт.
3. Добавить `pgadmin` как отдельный сервис для управления PostgreSQL.
4. Настроить Persisted volume для Postgres и HDFS.
5. Включить в Compose контейнер с простым producer (Python) отправляющим сообщения в Kafka.
6. Добавить healthcheck для каждого сервиса.
7. Реализовать restart policy for containers (on-failure).
8. Добавить сетевой alias и разместить персистентные логи в отдельный каталог.

9. Создать script `start.sh` и `stop.sh` с обработкой graceful shutdown.
10. Подготовить `Dockerfile` для простого consumer'a, который пишет сообщения в PostgreSQL.

Критерии оценивания:

- **Корректность развёртывания (0–2 балла):** все сервисы стартуют и доступны (2 — да, 1 — частично, 0 — не стартуют).
- **Интеграция сервисов (0–1 балл):** запись в HDFS, сообщение в Kafka, вставка в Postgres (1 — реализовано).
- **Документация и скрипты (0–1 балл):** README с инструкцией запуска + скрипты (1 — есть).
- **Качество конфигурации (0–1 балл):** корректные volumes, healthchecks, политики restart (1 — корректно).
-

8.3. Лабораторная работа №2. Интеграция PostgreSQL ↔ HDFS: экспорт, импорт, контроль форматов

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 1-6

Форма обучения: очная

Цель: настроить и продемонстрировать способы движения табличных данных между PostgreSQL и HDFS, оценить потери/изменения формата, настроить проверки.

План выполнения:

1. Подготовка таблицы в PostgreSQL (пример: транзакции/логи).
2. Экспорт таблицы в CSV (`pg_dump/copy to`) и загрузка в HDFS.
3. Конвертация CSV → Parquet (используя Spark/pyarrow).
4. Импорт Parquet обратно в PostgreSQL (через staging + COPY или через Spark JDBC).
5. Сравнение исходного и восстановленного набора (row count, checksum выборки).
6. Оформление отчёта с выводами о потерях/изменении типов.

Варианты задания:

1. Экспортировать таблицу с BLOB-полем и организовать хранение BLOB отдельно.
2. Экспортировать с разностью кодировок (UTF-8 vs Latin1) и исправить при импорте.
3. Конвертация CSV→Parquet с сохранением метаданных (schema).
4. Использовать `scoop` (если доступен) для переноса и оценить.
5. Выполнить bulk-load в PostgreSQL через `COPY` из локального файла, с проверкой транзакций.
6. Импортировать в PostgreSQL с преобразованием типов (string→timestamp).
7. Оценить скорость при разных размерах batch при импорте.
8. Сравнить результат при использовании разных парсеров (pandas vs pyarrow).
9. Реализовать автоматическую проверку схемы (schema registry-like).
10. Реализовать этап валидации и отката при несоответствии количества строк.

Критерии оценивания:

- **Корректность переноса (0–2 балла):** корректный экспорт/импорт, совпадение row count и выборочной проверки (2 — совпадает, 1 — частично, 0 — не совпадает).
- **Обработка типов/кодировок (0–1):** корректная обработка типов и кодировок (1 — да).
- **Автоматизация и скрипты (0–1):** наличие скрипта/инструкции для повторения процесса (1 — да).
- **Анализ и отчёт (0–1):** выводы о потерях, рекомендациях (1 — содержательно).

8.4. Лабораторная работа №3. Оптимизация и профилирование SQL-запросов в PostgreSQL под аналитическую нагрузку

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 1-6

Форма обучения: очная

Цель: научиться профилировать запросы, читать EXPLAIN ANALYZE, применять индексы, материализованные представления и оптимизировать запросы.

План выполнения:

1. Подготовка набора больших таблиц (несколько миллионов строк имитируемых данных).
2. Выбор «тяжёлого» аналитического запроса (JOIN + GROUP BY).
3. Профилирование запроса EXPLAIN ANALYZE.
4. Применение оптимизаций: индексы (B-tree, partial), cluster, VACUUM/ANALYZE.
5. Создание материализованного представления при необходимости.
6. Сравнение времени до/после и оформление отчёта.

Варианты задания:

1. Добавить индекс по колонке, участвующей в фильтре, сравнить.
2. Создать частичный индекс для часто используемого диапазона дат.
3. Применить CLUSTER по индексу и оценить влияние.
4. Использовать materialized view для ускорения агрегации.
5. Переписать JOIN в CTE и сравнить производительность.
6. Использовать EXPLAIN (BUFFERS, ANALYZE) и проанализировать IO.
7. Сравнить производительность при разном fillfactor индекса.
8. Провести тест с параллельными запросами и оценить contention.
9. Настроить autovacuum параметры и оценить влияние.
10. Применить partitioning по дате и сравнить.

Критерии оценивания:

- **Улучшение производительности (0–2):** измеримо и документировано (2 — значительное улучшение >х%, 1 — небольшое, 0 — нет улучшения).
- **Правильность применения оптимизаций (0–1):** корректные решения по индексам/partitioning (1 — да).
- **Документация и репорт (0–1):** отчёт с EXPLAIN и выводами (1 — есть).
- **Качество эксперимента (0–1):** корректные замеры, реплицируемость (1 — да).

8.5. Лабораторная работа №4. Разработка Spark-job для агрегации данных из HDFS

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 7-12

Форма обучения: очная

Цель: реализовать и отладить Spark-задачу (PySpark или Scala) для чтения данных из HDFS, агрегации и записи результата в Parquet/Postgres.

План выполнения:

1. Подготовить тестовый набор данных в HDFS (логи/транзакции).
2. Создать Spark-приложение (локально или в кластере) с использованием DataFrame API.
3. Реализовать агрегации (groupBy, window-функции при необходимости).
4. Оптимизировать job (persist, partition, broadcast join при необходимости).
5. Запись результатов в Parquet и/или PostgreSQL.
6. Профилирование и отчёт о производительности.

Варианты задания:

1. Агрегировать количество событий по дням и по статусу.
2. Реализовать sliding window агрегацию (по времени).
3. Использовать broadcast join при малой таблице справочников.
4. Сохранить результат как partitioned Parquet (по дате).
5. Провести оптимизацию shuffle и измерить разницу.
6. Имплементировать UDF для сложного преобразования.
7. Использовать vectorized UDF (pandas_udf) где возможно.
8. Обработать corrupt/malformed строки безопасно (bad records handling).
9. Реализовать checkpointing для длинного job.

10. Выпустить job с конфигами памяти/parallelism и показать влияние.

Критерии оценивания:

- **Функциональность (0–2):** корректно считает агрегации и сохраняет результат (2 — полностью).
- **Оптимизация и ресурсы (0–1):** применены persist/partition/broadcast при необходимости (1 — да).
- **Документация и запуск (0–1):** README и параметры запуска (1 — да).
- **Качество кода (0–1):** читаемость, обработка ошибок (1 — да).

8.6. Лабораторная работа №5. Построение feature-store и выгрузка признаков для модели

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 7-12

Форма обучения: очная

Цель: реализовать простейший feature store (файловая/DB-реализация) — подготовка, версионирование и выгрузка признаков для офлайн-тренировки модели.

План выполнения:

1. Выбрать предметную область и набор признаков (например: user-session, транзакции).
2. Реализовать pipeline подготовки признаков (Spark/Pandas).
3. Сохранить признаки в Parquet и таблицу PostgreSQL (как feature table).
4. Реализовать версионирование (версия признака, timestamp).
5. Реализовать скрипт выгрузки набора признаков для обучения (join по ключу + фильтр по версии).
6. Оформить доклад с примером использования (train/test split).

Варианты задания:

1. Feature: скользящее среднее по 7/30 дней.
2. Feature: количество уникальных событий за N дней.
3. Feature: лаг-фичи (previous value).
4. Версионирование признаков при исправлении формулы.
5. Экспорт признаков в Parquet+catalog.
6. Сохранение в PostgreSQL с историей (valid_from/valid_to).
7. Реализация TTL для старых версий.
8. Обеспечить idempotent-pipeline (повторный запуск не ломает данные).
9. Реализовать simple lineage (какие сырые таблицы использованы).
10. Реализовать скрипт проверки качества признаков (null share, distribution change).

Критерии оценивания:

- **Полнота feature-pipeline (0–2):** признаки корректно рассчитаны и выгружены (2 — да).
- **Версионирование/репродуцируемость (0–1):** есть versioning и скрипт выгрузки (1 — да).
- **Документация и пример использования (0–1):** README + пример train-data (1 — да).
- **Качество (0–1):** проверки качества/набор метрик для фич (1 — да).

8.7. Лабораторная работа №6. Построение поиска по неструктурированным документам (JSON/documents)

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 7-12

Форма обучения: очная

Цель: организовать хранение и поиск по документам (JSON), реализовать индексирование и простую полнотекстовую выдачу (на основе Elasticsearch/SQLite FTS/инлайнового индекса).

План выполнения:

1. Подготовка набора неструктурированных документов (JSON с текстом, метаданными).
2. Развёртывание поискового движка (Elasticsearch) или использование альтернативы.
3. Индексирование документов, настройка маппинга/анализаторов.
4. Реализация запросов: полнотекстовый поиск, фильтрация по метаданным, фасеты.
5. Оценка качества поиска (precision@k для наборов тестовых запросов).
6. Документирование и демонстрация.

Варианты задания:

1. Индексировать новости с различными полями и искать по title+body.
2. Настроить ngram-анализатор для поиска по частям слов.
3. Реализовать поиск по фразе и по словам (match vs match_phrase).
4. Добавить фильтр по дате/тегам.
5. Создать подсказки (suggesters) для автодополнения.
6. Проанализировать recall/precision на подготовленном наборе.
7. Настроить highlight результата.
8. Индексировать и искать JSON-поля с вложенными списками.
9. Использовать vector-search (если доступно) для схожести embedding'ов (опционально).
10. Реализовать backup/restore индекса.

Критерии оценивания:

- **Функциональность поиска (0–2):** запросы работают, результаты релевантны (2 — да).
- **Настройка индексирования (0–1):** корректные анализаторы/маппинг (1 — да).
- **Оценка качества (0–1):** расчёт precision/recall для тестовых запросов (1 — да).
- **Документация (0–1):** README + примеры запросов (1 — да).

8.8. Лабораторная работа №7. Реализация CI/CD-пайплайна для простого ETL-проекта (локальный вариант)

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 13-18

Форма обучения: очная

Цель: реализовать локальный CI/CD для ETL-задачи с проверками качества данных и автоматическим деплоем контейнера.

План выполнения:

1. Инициализация репозитория (git) с ETL-скриптом (Python/Spark).
2. Написание unit-тестов для ключевых преобразований (pytest).
3. Dockerfile для ETL-контейнера.
4. Конфигурация локального pipeline (например, GitHub Actions / GitLab CI minimal или симуляция скриптом).
5. Настройка этапов: build → test → image build → deploy (локально).
6. Документирование и демонстрация pipeline.

Варианты задания:

1. Настроить GitHub Actions workflow с 3 шагами (build/test/docker build).
2. Использовать self-hosted runner (секция имитации).
3. Добавить stage для проверки качества данных (скрипт, который падает при >X% null).
4. Настроить multi-stage Dockerfile (build + runtime).
5. Реализовать release tagging при успешном CI.
6. Добавить сканирование безопасности зависимостей (safety/bandit).
7. Прикрутить деплой контейнера локально через docker compose pull/up.
8. Настроить кэширование зависимостей в CI (pip cache).
9. Организовать артефактную публикацию image в локальный registry (Harbor/minikube registry).
10. Интегрировать тест покрытия (coverage report).

Критерии оценивания:

- **CI работает и проходит тесты (0–2):** workflow/скрипт запускается и проходит (2 — полностью).
- **Качество тестов (0–1):** покрыты ключевые сценарии (1 — да).
- **Dockerization и deploy (0–1):** контейнер собирается и запускается (1 — да).
- **Документация и reproducibility (0–1):** README с инструкцией запуска CI (1 — да).

8.9. Лабораторная работа №8. Настройка мониторинга и алертов для стримингового решения

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 13-18

Форма обучения: очная

Цель: собрать практическую систему мониторинга для Kafka→consumer→Postgres pipeline и настроить алерты.

План выполнения:

1. Развёртывание minimal monitoring stack (Prometheus + Grafana) или сбор логов/метрик в файлы.
2. Установка exporter'ов/скриптов для Kafka lag, PostgreSQL metrics и консьюмера.
3. Построение dashboard с ключевыми метриками (lag, throughput, errors, db connections).
4. Настройка alert rule (в Prometheus Alertmanager или эмуляция).
5. Тестирование сгенерированного инцидента и документирование действий.

Варианты задания:

1. Настроить alert на lag > threshold и эскалацию.
2. Настроить alert на долгие транзакции в PostgreSQL.
3. Добавить мониторинг GC/heap JVM для Kafka (если используется JVM image).
4. Реализовать мониторинг consumer errors и rate of errors.
5. Включить алерт на low-disk на DataNode (HDFS).
6. Настроить webhook или отправку email (симуляция) при алерте.
7. Сгенерировать нагрузку и показать реакцию alert.
8. Добавить запись root cause в отдельную таблицу при алерте.
9. Настроить Grafana alerting с уведомлением в канал (симуляция).
10. Подготовить playbook реакции на конкретный alert.

Критерии оценивания:

- **Сбор метрик (0–2):** все необходимые метрики доступны (2 — да).
- **Настройка dashboard (0–1):** информативный dashboard (1 — да).
- **Настройка алертов и тест инцидента (0–1):** alert сработал при симуляции (1 — да).
- **Документация + playbook (0–1):** есть инструкция реакции (1 — да).

8.10. Лабораторная работа №9. Итоговая лаборатория: сборка и демонстрация end-to-end пайплайна (финальная интеграция для проекта)

Тип оценочного средства (предмет контроля): защита отчета

Перечень контролируемых тем (модулей): темы 13-18

Форма обучения: очная

Цель: собрать и представить работающее end-to-end решение: ingestion (Kafka), storage (HDFS/Postgres), processing (Spark), monitoring, CI-скелет — как часть подготовки к практическому проекту.

План выполнения:

1. Объединить ранее реализованные компоненты (Docker Compose / scripts).
2. Настроить поток: producer → Kafka → consumer/Spark → write to Postgres + write to Parquet.
3. Добавить мониторинг и CI-проверки (минимально).

4. Провести демонстрационный сценарий: от генерации данных до визуализации/запроса результата.

5. Сформировать итоговый отчёт и презентацию (краткое видео/скринкаст приветствуется).

Варианты задания:

1. Pipeline для логов веб-приложения: агрегация по URL и сохранение в DW.
2. Pipeline для событий транзакций с feature generation (скользящие окна).
3. Pipeline с обработкой ошибок и dead-letter queue.
4. Pipeline с offline inference: применение модели на batch результатах.
5. Pipeline с хранением raw → processed → features (lakehouse style).
6. Pipeline с поддержкой schema evolution (Avro/Schema registry).
7. Pipeline с checkpointing и exactly-once semantics (по возможности).
8. Pipeline с интеграцией feature store (сохранение фич в Postgres).
9. Pipeline с демонстрацией rollback (replay) при ошибке.
10. Pipeline с end-to-end тестами (automated smoke tests).

Критерии оценивания:

- **End-to-end работоспособность (0–2):** весь поток работает и демонстрирует результат (2 — да).
- **Надёжность/обработка ошибок (0–1):** dead-letter, retry, откат/повтор — реализованы (1 — да).
- **Мониторинг и CI базовая интеграция (0–1):** метрики + workflow (1 — да).
- **Документация и презентация (0–1):** отчёт, инструкция и демонстрация (1 — да).

8.11. Кейс-задание №1

(выполнение, подготовка отчёта, защита отчёта)

Тип оценочного средства: кейс-задание

Тип контроля: текущий

Перечень контролируемых тем (модулей): Модуль 1

Форма обучения: очная

Семинар №1. Работа с HDFS — базовые операции

Цель: освоить загрузку/чтение/удаление/копирование файлов в HDFS, проверить параметры репликации и целостность.

План занятия: подключение; создание каталогов; загрузка файлов; `hdfs dfs -ls /cp/mv/rm`; `hdfs fsck`; проверка репликации; сбор логов.

Варианты задания: 1) загрузить CSV набор; 2) установить replication=2; 3) копировать между users; 4) восстановить удалённый файл; 5) подсчитать блоки; 6) измерить время записи 100MB; 7) загрузить JSON и проверить права; 8) создать квоту для папки; 9) сравнить загрузку gzip vs plain; 10) симулировать отказ DataNode и показать реплицирование.¶

Семинар № 2. MapReduce — простые задания (WordCount и вариации)

Цель: реализовать MapReduce (Java/PyStream/Hadoop Streaming), понять map/reduce и запуск job.

План: подготовка данных; написание mapper/reducer; пакетирование; запуск job; анализ логов/времени.

Варианты задания: WordCount; подсчёт уникальных слов; top-N слов; подсчёт ошибок в логах; подсчёт IP-address frequency; средняя длина строки; подсчёт по дням; распределение по статусу; сортировка по числу; сравнение времени для нескольких input sizes.

Семинар №3. Развёртывание Kafka + продюсер/консьюмер

Цель: поднять Kafka, создать топики, реализовать продюсер/консьюмер, измерить базовые метрики.

План: запустить ZK/Kafka; создать topic; реализовать producer/consumer (CLI/Python); проверить офсеты, партиции; измерить latency.

Варианты задания: тема logs с 3 партициями; producer на 100 сообщений; consumer count; настройка auto.offset.reset; multi-producer scenario; ключевые сообщения; проверка порядка; симуляция перегрузки; producer с ключами; consumer group behaviour

Семинар №4. PostgreSQL — основные операции и индексы

Цель: создание БД/таблиц, CRUD, индексы, EXPLAIN простых запросов.

План: создать БД; таблицы; вставка данных; SELECT/JOIN; создать индекс; EXPLAIN ANALYZE.

Варианты задания: студент таблица; индекс по фамилии; join нескольких таблиц; агрегации; создание view; экспорт в CSV; обновление по условию; удаление старых записей; сравнение времени с/без индекса; измерить время больших insert'ов.

Семинар №5. Форматы данных: CSV ⇄ JSON ⇄ Parquet/Avro

Цель: конвертация файлов, измерение размеров и скоростей чтения/записи.

План: подготовить CSV; конвертировать в JSON/Parquet/Avro (pandas/pyarrow/spark); проверить schema; измерить time/io.

Варианты задания: CSV→Parquet; JSON→Avro; Parquet→CSV; сравнение сжатий; замер скорости чтения; сохранить schema; compare pyarrow vs pandas; сжатие snappy/gzip; добавить corrupt rows handling; evolution of schema

Семинар №6. ETL: Kafka → PostgreSQL (простая интеграция)

Цель: реализовать consumer, который пишет события из Kafka в PostgreSQL с проверкой целостности.

План: создать topic; подготовить таблицу; реализовать consumer (batch/stream insert); обработка ошибок; проверка данных.

Варианты задания: JSON→SQL; CSV→SQL; batch inserts; upsert/ON CONFLICT; парсинг timestamp; агрегация в consumer; dead-letter queue; metrics (success/fail); idempotent consumer; тестирование восстановления.

Семинар №7. Бэкап и восстановление PostgreSQL

Цель: освоить pg_dump, pg_restore, physical backup, WAL->PITR, automation.

Семинар №8. Мониторинг логов и метрик (основы)

Цель: собрать метрики (Prometheus/ELK alternatives) и показать 3–4 дашборда/alert.

Семинар №9. Data Quality: completeness, uniqueness, validity

(подробности — уже описаны ранее)

Цель: реализовать проверки качества и простую автоматизацию report → action

Критерии оценки:

5 баллов выставляется студенту, если он своевременно выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал полноту теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на дополнительные вопросы, связанные не только с процессом выполнения задания, но и с пониманием совершенных действий и решенных задач.

4 балла выставляется студенту, если он выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал наличие достаточных теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на вопросы, связанные с процессом выполнения задания.

3 балла выставляется студенту, если он более чем на половину выполнил задания в рамках семинаров, способен ответить на вопросы, касающиеся теоретической составляющей в объеме содержания учебной дисциплины, относящейся к кейсовому заданию.

0 баллов выставляется студенту, при невыполнении требований, предусмотренных в случае удовлетворительной оценки.

8.12. Кейс-задание №2

(выполнение, подготовка отчёта, защита отчёта)

Тип оценочного средства: кейс-задание

Тип контроля: текущий

Перечень контролируемых тем (модулей): Модуль 2

Форма обучения: очная

Семинар №10. Проектирование архитектуры потоковой обработки (Design)

Цель: уметь спроектировать real-time pipeline, оценить bottlenecks.

План: анализ требования; архитектурная диаграмма; компонентное обоснование; краткий TCO/SLA анализ.

Варианты задания: веб-логи, IoT, финтех, дашборды, безопасность, соцсети, Kafka→HDFS

Семинар №11. Настройка Kafka Connect (Source/Sink)

Цель: конфигурировать connector'ы для интеграции БД/файлов/ELK.

План: запуск Connect; конфигурация JSON; подключение source/sink; мониторинг статуса tasks; тест.

Варианты задания: CSV→Postgres, Postgres→Kafka, REST→Kafka, Kafka→HDFS, Kafka→ES, и т.д.)

Семинар №12. Очистка потоков (stream cleansing)

Цель: реализовать фильтрацию/нормализацию в стриме (Kafka Streams/ksqlDB/Spark Structured Streaming).

План: построить стрим-топологию; очистка null/типов; дубликаты; enrich; sink to PostgreSQL.

Варианты задания: фильтрация ошибок; типизация; dedup; timestamp normalization; enrich with lookup table; computed fields; rate limiting; drop malformed; convert encodings; merge streams.

Семинар №13. Реализация DataOps-pipeline (Git + test + deploy)

Цель: автоматизировать проверки и сборку ETL/connector-конфигураций.

План: репозиторий; тесты (unit/data checks); CI workflow (build/test/docker); демонстрация deploy.

Варианты задания: автоматизация коннекторов; schema checks; test data generation; release tagging; security scan; cache deps; publish artifact; deploy to local registry; auto rollback script; coverage

Семинар №14. Репликация PostgreSQL (master-standby)

Цель: настроить physical/logical replication и протестировать failover.

План: настроить master; pg_basebackup; standby; проверка синхронизации; имитация failover.

Варианты задания: physical replication; logical replication; hot_standby; pg_rewind; measure lag; setting wal_level; replication slots; read_only standbys; promote standby; backup automation.

Семинар №15. Мониторинг распределённых систем (углублённо)

Цель: собрать метрики кластеров, создать дашборды и alerts (HDFS/Kafka/Postgres).

План: развёртывание exporters; настройка Prometheus; Grafana dashboards; Alertmanager rules; тестирование.

Варианты задания: мониторинг HDFS disk; Kafka lag; Postgres qps; alert на disk/lag/long queries; GC metrics; consumer errors; network IO; node health; throughput per topic; retention.

Семинар №16. Оптимизация SQL в PostgreSQL (практическая отладка)

Цель: проанализировать планы, подобрать индексы, partitioning, materialized views.

План: heavy query; EXPLAIN ANALYZE; добавить индексы/partition; VACUUM/ANALYZE; сравнить.

Варианты задания: composite indexes; partial index; partition by date; materialized view; CTE vs subquery; jsonb index; CLUSTER; fillfactor; parallel queries; tune autovacuum.

Семинар №17. Масштабирование Kafka: добавление брокеров и rebalance

Цель: корректно увеличить кластер, перераспределить партиции и измерить эффект.

План: добавить broker; run partition reassignment; validate replicas; measure throughput/latency.

Варианты задания: add broker; change replication factor; rebalance topics; test failover; measure latency; set quotas; run parallel producers; test ISR behavior; migration script; monitor reassign progress.

Семинар №18. Отказоустойчивость и восстановление систем (end-to-end)

Цель: совместно использовать методы бэкапа/restore и восстановить работоспособность после инцидента.

План: snapshot topics; pg_dump + pg_restore; simulate node crash; restore; validate data.

Варианты задания: snapshot Kafka; WAL-based PITR; restore Postgres; restore HDFS block; test data consistency; test restore time; DR playbook; incremental restore; smaller RPO tests; measure RTO.

Критерии оценки:

5 баллов выставляется студенту, если он своевременно выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал полноту теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на дополнительные вопросы, связанные не только с процессом выполнения задания, но и с пониманием совершенных действий и решенных задач.

4 балла выставляется студенту, если он выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал наличие достаточных теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на вопросы, связанные с процессом выполнения задания.

3 балла выставляется студенту, если он более чем на половину выполнил задания в рамках семинаров, способен ответить на вопросы, касающиеся теоретической составляющей в объеме содержания учебной дисциплины, относящейся к кейсовому заданию.

0 баллов выставляется студенту, при невыполнении требований, предусмотренных в случае удовлетворительной оценки.

8.13. Кейс-задание №3

(выполнение, подготовка отчёта, защита отчёта)

Тип оценочного средства: кейс-задание

Тип контроля: текущий

Перечень контролируемых тем (модулей): Модуль 3

Форма обучения: очная

Семинар №19. CI/CD для ETL с автоматическими тестами качества данных

Цель: развернуть workflow, где при push запускаются тесты качества данных и unit-тесты ETL.

План: описать pipeline; написать тесты (pytest + data quality checks); GitHub Actions/GitLab CI workflow; демонстрация.

Варианты задания: threshold null% fail; uniqueness test; schema evolution test; smoke test; integration test (local services); test coverage; caching dependencies; artifact storage; multi-stage workflow; gated deploy.

Семинар №20. Containerization: Dockerize ETL and services

Цель: контейнеризовать ETL и вспомогательные скрипты, подготовить multi-stage Dockerfile.

План: написать Dockerfile; multi-stage build; минимизация image size; docker-compose для локального запуска; тестирование.

Варианты задания: multi-stage build; caching pip; non-root user; healthcheck; env vars handling; secret via files; small base images; produce logs; mount volumes for dev; publish to local registry.

Семинар №21. Infrastructure as Code (введение) — простая автоматизация конфигурации

Цель: применить Ansible/Terraform (демонстрационно) для provisioning dev-окружения (либо симуляция).

План: написать простой playbook/terraform config; запустить provisioning в локальной VM/контейнерах; проверить.

Варианты задания: terraform provision docker host; ansible install postgres; ansible configure kafka; terraform create volumes; parameterize configs; idempotent playbook; use variables/secret; state file handling; dry-run; rollback.

Семинар №22. Тестирование моделей и автоматическая валидация перед релизом

Цель: внедрить простую валидацию модели (smoke tests, performance) и интегрировать проверку в CI.

План: подготовить модель (скор в памяти), тесты на accuracy/basic metrics, pipeline для теста при push, хранение метрик.

Варианты задания: unit tests for preprocessing; model accuracy threshold; performance (latency) test; model serialization test; reproducibility check; model size check; integration to feature store; CI gating; rollback model; store metrics.

Семинар №23. Трассировка данных и lineage (простейшая реализация)

Цель: реализовать простую систему lineage: откуда пришёл признак/строка и куда ушла.

План: добавить metadata/logging при каждом шаге ETL; хранить lineage в таблице; реализовать simple query for upstream/downstream.

Варианты задания: lineage for feature; lineage for table; automatic logging; store provenance; UI simple query; rollback via lineage; join lineage + timestamp; capture commit id; map raw→processed→features; provenance for model input.

Семинар №24. Security practices: secrets, RBAC, TLS basics

Цель: внедрить базовые практики безопасности: хранение секретов, RBAC для Postgres/Kafka, TLS for Kafka/Postgres (демо).

План: генерация self-signed certs; configure TLS for one service; create roles and grant permissions; store secrets in env file/vault simulation.

Варианты задания: TLS for Kafka; TLS for Postgres; Kerberos demo (описательно); RBAC roles; rotating secrets; use HashiCorp Vault (демо); limit user privileges; audit logs; encrypt data at rest simulation; secret in CI pipeline protected.

Семинар №25. Incident response & runbooks — практическое упражнение

Цель: подготовить playbook и отработать сценарий инцидента (lag, node down, data corruption).

План: выбрать scenario; составить runbook; симулировать incident; применить runbook; зафиксировать метрики/RTO.

Варианты задания: consumer lag incident; DataNode down; Postgres long tx; Kafka broker down; schema change break; data corruption; backup failure; storage full; high latency; failed deploy.

Семинар №26. Подготовка отчёта и презентации проектной работы (preparation)

Цель: научиться систематизировать результаты работы в репозитории, подготовить презентацию и demo.

План: собрать артефакты; написать README; подготовить демо-скрипт; оформить презентацию 5–7 слайдов; краткое видео/скринкаст.

Варианты задания: doc для лог pipeline; demo сценарий; test suite; CI-badge; architecture diagram; performance numbers; cost estimate; security checklist; handover instructions; lessons learned.

Семинар №27. Подготовка и защита мини-проекта (репетиция перед экзаменом)

Цель: репетиционно провести защиту проекта: демонстрация, Q&A, согласование критериев оценки.

План: демонстрация end-to-end; показать основные артефакты; ответить на вопросы; получить фидбек; доработки.

Варианты задания: demo scenario as in lab9 variants (logs, tx, features, DL inference, dead-letter, schema evolution и т.д.).

Критерии оценки:

5 баллов выставляется студенту, если он своевременно выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал полноту теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на дополнительные вопросы, связанные не только с процессом выполнения задания, но и с пониманием совершенных действий и решенных задач.

4 балла выставляется студенту, если он выполнил все задачи, предусмотренные в рамках семинаров, подготовил отчет в соответствии с требованиями преподавателя и в процессе защиты продемонстрировал наличие достаточных теоретических знаний в объеме содержания учебной дисциплины, относящейся к кейсовому заданию. Сумел ответить на вопросы, связанные с процессом выполнения задания.

3 балла выставляется студенту, если он более чем на половину выполнил задания в рамках семинаров, способен ответить на вопросы, касающиеся теоретической составляющей в объеме содержания учебной дисциплины, относящейся к кейсовому заданию.

0 баллов выставляется студенту, при невыполнении требований, предусмотренных в случае удовлетворительной оценки.

8.14. Экзаменационные вопросы и билеты для семестра 7

Период контроля: 7 семестр

Тип оценочного средства (предмет контроля): экзамен

Цель: Оценить сформированность профессиональных компетенций в области проектирования, развёртывания и эксплуатации инфраструктуры распределённых систем хранения и обработки данных, а также умение интегрировать технологии Hadoop, Kafka и PostgreSQL в единую производственную DataOps-среду.

Содержание задания

Общая идея экзаменационного проекта

Студент должен спроектировать, реализовать и продемонстрировать end-to-end Data Pipeline, включающий:

1. Источник данных (файлы/поток Kafka/синтетический генератор);
2. Транспорт данных через Kafka;
3. Обработку данных (очистка, агрегация, enrichment);
4. Хранилище данных (PostgreSQL / HDFS);
5. Минимальный модуль аналитики или ИИ (feature extraction, scoring);

6. Мониторинг и контроль качества данных (Data Quality/Logging);
7. CI/CD-автоматизацию для развёртывания и тестирования конвейера.

Требования к реализации

Компонент	Минимальные требования
Kafka	1 topic, producer и consumer (CLI или Python/Java), работающие в Docker
PostgreSQL	Таблицы для хранения очищенных данных, индексирование, тестовый SQL-запрос
Обработка данных	Минимум 3 шага: ingest → transform → store
Мониторинг	Логирование и метрики (например, Prometheus или простая статистика в логах)
CI/CD	Workflow (GitHub Actions / GitLab CI), автоматический тест или линтинг
Отчёт	README + отчёт PDF/MD (архитектура, скриншоты, команды, анализ)
Презентация	5–7 слайдов с архитектурой, скриншотами и выводами

Индивидуальные варианты заданий

1. Поток логов веб-сервера → Kafka → PostgreSQL: парсинг строк, агрегация по IP, суточные метрики.
2. Сенсорные данные IoT → Kafka → HDFS → PostgreSQL: фильтрация и усреднение показаний.
3. Финансовые транзакции → Kafka → PostgreSQL: выявление подозрительных операций.
4. Сообщения чата → Kafka → PostgreSQL: анализ частоты сообщений и топ слов.
5. События из CSV-файлов → Kafka → PostgreSQL: проверка полноты и валидности данных.
6. Мониторинг нагрузки серверов → Kafka → PostgreSQL: расчёт средних метрик CPU/RAM.
7. Данные о заказах → Kafka → PostgreSQL: агрегация по пользователям и регионам.
8. События логов приложений → Kafka → PostgreSQL: выявление ошибок и их частоты.
9. Телеметрия устройств → Kafka → PostgreSQL: хранение и контроль пропусков данных.
10. Анализ отзывов клиентов (JSON) → Kafka → PostgreSQL: простая тональная классификация (через ключевые слова).

Формат отчёта

Файл: report.pdf или report.md

Содержание:

1. Титульный лист (ФИО, группа, вариант, дата);
2. Цель работы;
3. Архитектура решения (диаграмма);
4. Описание компонентов (Kafka, обработка, БД);
5. Скриншоты работы системы;
6. Ключевые команды запуска (docker-compose, CI);
7. Результаты тестирования;
8. Выводы и анализ (bottlenecks, улучшения).

Формат защиты проекта

1. Демонстрация работающего пайплайна (3–5 минут);
2. Объяснение архитектуры и инструментов;
3. Ответы на 2–3 вопроса преподавателя;
4. Краткая саморефлексия: какие проблемы возникли, что можно улучшить.

Критерии оценивания

Критерий	Балл	Описание
1. Архитектура и корректность реализации	0–10	10 — реализован полный пайплайн; 5 — частично; 0 — нет
2. Качество кода и конфигураций	0–8	Чистота, читаемость, документация
3. Корректность данных и результат анализа	0–7	Данные загружаются, корректно обрабатываются
4. CI/CD и DataOps автоматизация	0–5	Есть workflow, тесты, сборка
5. Мониторинг и отчёт	0–5	Метрики, логи, отчёт
6. Презентация и защита	0–5	Лаконичность, уверенность, понимание
ИТОГО (макс.)	40 баллов	

Пример структуры проекта в репозитории

```

project-root/
├── docker-compose.yml
├── kafka/
│   ├── producer.py
│   └── consumer.py
├── postgres/
│   ├── init.sql
│   └── schema.sql
├── etl/
│   ├── transform.py
│   └── pipeline.sh
├── ci/
│   └── workflow.yml
├── report/
│   └── report.md
├── presentation/
└── ── slides.pdf

```